基于 FPGA 的床旁超声心动图实时全心功能评估系统

摘要

床旁与急诊需要在扫查当下判断左室收缩功能，而现有标记手段存在两点重要不足：人工测量的射血分数（EF）在描记与定帧上存在系统性差异，近年出现的超声机集成自动化工具输出参数仅单一结果数据，医生在系统出错时难以修正，甚至难以发现错误。本作品在 Zynq UltraScale+ XCZU3EG 开发板上实现了心尖四腔心超声视频的实时全心功能评估：PL 中自研的 U-Net 张量引擎完成心腔分割与后处理，PS 完成关键帧调度、斑点跟踪和临床测量。

设计围绕三个问题。第一，PL 分割一帧需 22.9 ms，长于超声机输出视频常用的 50 fps 的帧间隔。我们利用“EF 只取决于舒张末和收缩末两个重要时刻”的特点，只把约 18% 的重要时刻关键帧送入 PL，其余帧由 NEON 跟踪，每帧处理时间从帧预算的 121% 降到 26%，延迟 P50 29 ms、P99 67 ms，EF 误差保持不变。第二，片上存不下整层张量，PS 读 PL 又很慢。我们设计条带调度的张量引擎并完成 6 项实测优化，512×512 整网计算耗时从 2076 ms 降到 292.8 ms，比同板 4 核 NEON 快 1.93 倍。第三，结果要可信、可扩展：引擎换权重即可实现不同功能，相同输入重复 20 次输出结果完全相同。

在 EchoNet-Dynamic 测试集 1277 段视频上，EF 平均绝对误差 5.39%，左室 Dice 0.908。设计占用 LUT 75.40%、BRAM 63.2%、DSP 80.6%，152.15 MHz 下时序收敛；PL 动态功耗估算约 0.9 W，整板实测 6–7 W。系统仅输出辅助测量和复核提示，不作为诊断依据。

关键词：FPGA；超声心动图；射血分数；关键帧调度；U-Net 加速

目　录

第一部分 作品概述 3

1.1 功能与特性 3

1.2 应用领域 4

1.3 主要技术特点 6

1.4 主要性能指标 6

1.5 主要创新点 7

1.6 设计流程 7

第二部分 系统组成及功能说明 8

2.1 整体介绍 8

2.2 硬件系统介绍 9

2.3 软件系统介绍 12

第三部分 完成情况及性能参数 14

3.1 整体介绍 14

3.2 工程成果 15

3.3 特性成果 16

第四部分 总结 20

4.1 可扩展之处 20

4.2 心得体会 20

第五部分 参考文献 20

第一部分 作品概述

1.1 功能与特性

系统输入心尖四腔心超声视频：可以整段上传，也可以由板上信号源按原帧率逐帧送入。输出包括逐拍左室容积曲线与 EF、心衰分型（ESC 2021 [1]）、EF 的 80% 置信区间、区间跨过分型界值时的“建议复核”提示、6 节段室壁运动提示，以及右室、右房与左室的面积比。

系统有三种工作模式：快照模式做双平面 Simpson 测量，关键帧模式分析整段视频，现场模式边采边算实时输出。医生可在任一帧上点击纠错，FPGA 立即重算该帧并向后传播；结果可一键导出证据报告。全部计算在板上完成，图像不离开设备；同一输入结果逐位相同；板子接 DP 显示器即可脱离 PC 独立运行。图 1 为系统架构。

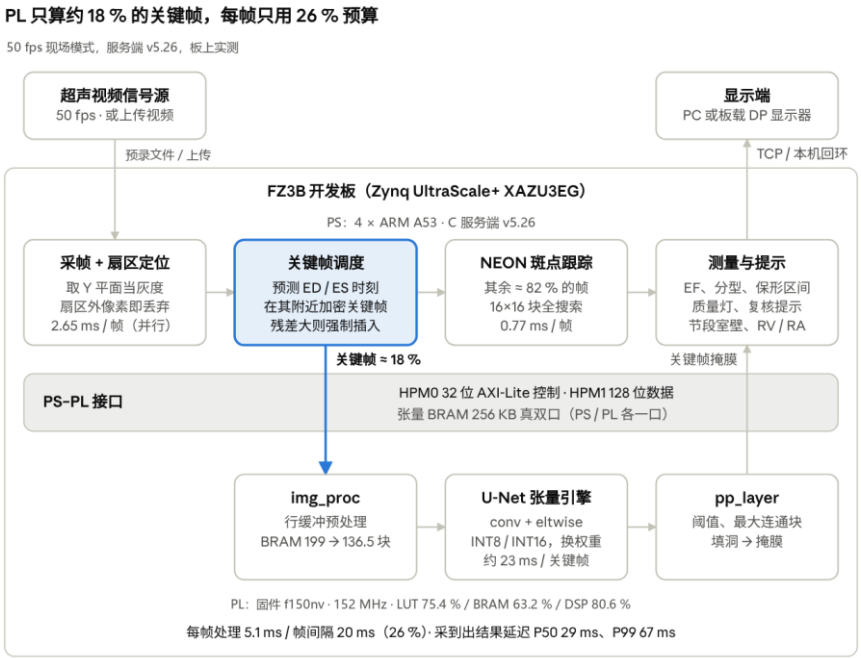


图 1 系统总体架构：PL（下排）负责分割与后处理，PS（中排）负责调度、跟踪和测量

1.2 应用领域

场景与形态。系统面向床旁与急诊的 A4C 切面快速评估：判断左心收缩功能、右心有无明显异常，并在 EF 接近分型界值时提示复核。我国 35 岁及以上成人心衰患病率约 1.3%（约 1370 万人）[2]，而基层与急诊普遍缺少有经验的超声医师；ESC 2021 以 EF ≤ 40%、41%–49%、≥ 50% 作为分型依据 [1]，也正是本系统输出“建议复核”的判定基准。形态上，本作品是一个旁路外挂在超声机视频输出口的小盒子：不改动在用设备、不绑定机型、图像不离开设备。

痛点一：人测 EF 的变异分三段，四十余年没有被消掉。早在 1983 年，就有研究实测 EF 的个体置信区间约 ±10%，并明确建议“同一受试者的系列测量最好由同一个人完成”[3]。四十余年后，在预先选定舒张末与收缩末帧、把采集与定帧排除在外的条件下，35 名有经验的超声医师独立描记 A4C / A2C 心内膜，LVEF 的观察者间相对标准差仍为 16.0 ± 3.4%、ICC 仅 0.187，作者据此质疑手动分割得到的 LVEF 能否作为稳健的诊断参考 [4]——这还只是描记一段。定帧一段的量级由 140 例分层研究给出：专家与初学者之间 LVEF 偏差 3.2、标准差 6.3，95% 一致性界限 −9.2% 至 +15.6%，**界限宽度 24.7 个百分点，是 ESC 分型带宽 10 个百分点的 2.5 倍** [5]；同一名患者换一位医师复测，读数从 HFrEF 一侧跨到 HFpEF 一侧都不算异常。以 CMR 为参照，超声 LVEF 的观察者间 ICC 为 0.80（0.53–0.92），CMR 为 0.96（0.90–0.98）[6]——这是方法学上限，不是操作者不够仔细。采集一段同样顽固：由全科医生、心脏科护士与心内科医师各自持手持设备完成采集与自动测量，操作者间 ICC 仅 0.35–0.51，被归为“poor”[7]。

痛点二：AI 给出的 EF 是一个不可审视、不可撤回的数字。综述把模型的

“黑箱性质”与数据偏倚、跨设备泛化不足并列，视为阻碍临床采纳的核心障碍 [8]。而一旦把黑箱打开，医生的接受度很高：基于网页的 AI 超声平台采用 human-in-the-loop 工作流，允许医生实时查看并修改分割掩膜，18 名心内科医师参与的多中心评估中 86% 的 AI 输出无需修改即被接受（学术医院 84%、私立心脏中心 88%）[9]。但接受率高不等于不需要入口——AI 引导的床旁心脏超声试点（AISAP-INOVA）中，心内科医师对 AI 检查的修正率仍为 27%，无 AI 辅助时为 47% [10]。既然有 14% 需要改、有 27% 需要专家介入，可改动的入口就是必要的；没有入口，这部分需求无处落地，医生手上只剩一个无法验证、也无法撤回的数字。

表 1　痛点、对策与可核查证据

痛点	本作品的对策	证据
描记：换人拉线结果漂移（RSD 16.0 ± 3.4%，ICC 0.187）	全整数确定性计算，同一输入结果逐位唯一	2 种运行方式 × 20 次重复，结果哈希仅 1 个
定帧：ED / ES 靠目测（一致性界限宽 24.7 个百分点）	心动周期自适应关键帧调度，自动定位并加密 ED / ES	关键帧 17.8%，Dice 损失 0.44%，EF MAE 5.35
采集：换探头角度、增益输入就变（操作者间 ICC 0.35–0.51）	不宣称消掉，用质量灯把发现问题的时间点前移到扫查中	CAMUS 区分差图像 AUC 0.911
输出不可验证（仍有 14% 输出被修改）	掩膜、逐拍容积曲线、80% 置信区间全量呈现	区间覆盖率 0.80（名义 80%）
输出不可撤回（复核修正率仍达 27%）	任一帧点击纠错，22 ms 重算并向后传播	板上实测单帧 22 ms

先用得上，才谈得上准。一次分析如果需要冻结、导出、等待，医师已经换了切面甚至离开了床。本作品边采边算：50 fps 源 174 帧不丢帧，每帧处理 5.1 ms（帧预算的 26%），端到端延迟 P50 29 ms、P99 67 ms 且不累积，整板 6–7 W、可脱离 PC 独立运行——同类便携超声系统同样把 FPGA 的确定性延迟与

低功耗作为相对 GPU / CPU 的核心优势，整机功耗预算可做到 7.9 W 量级 [11]。这几个数字的意义不在于快，而在于让上面两件事成立：质量灯能在扫查过程中亮，纠错能在医生手指离开鼠标之前完成。

可推广。引擎“换权重即换任务”，同一比特流已运行眼底血管、皮肤镜等分割程序，可延伸至其他需在设备端完成分割的医学影像场景，也可用于超声教学与质控。

1.3 主要技术特点

（1）**自研 U-Net 张量引擎**：卷积、逐元素、后处理三个 HLS 核，结构固定，输入尺寸和权重作为数据下发；INT8 为主、敏感节点用 INT16，结果为整数。

（2）**条带调度与搬运优化**：张量存储于 DDR，按条带搬入 256 KB 真双口 BRAM；GDMA 读回与下一条带写入并行，IP 计算期间 PS 不访问 BRAM。

（3）**PL / PS 异构分工**：PL 只算关键帧，PS 用 NEON 跟踪其余帧；处理线程每帧平均只用 5.1 ms。

（4）**单时钟域提频**：MMCM 将 101.376 MHz 倍频到 152.15 MHz，不改启动镜像，按实际时钟复核时序。

（5）**全链路可验证**：板上输出与 HLS 位级参考、离线整数模型三者逐位一致，每次更新固件都做全量回归。

1.4 主要性能指标

主要指标见表 2，测试条件逐项列出；与已发表工作的对比见 3.3 节。

表 2　主要性能指标

指标	结果	测试条件
实时性	50 fps 源 174 帧完整输出；每帧处理 5.1 ms，占帧预算 26%	板上预录信号源逐帧送入，板上时间戳
端到端延迟	采到帧 → 掩膜 + 容积：P50 29 ms、P99 67 ms	同上，推荐档
PL 引擎吞吐	128 档整网 22.0 ms；512 档整网 292.8 ms	含 PS 搬运，空载中位数
对比同板 CPU	4 核 NEON 的 1.93 倍，1 核 NEON 的 7.6 倍	512 档，同一整数模型，输出逐位相同
精度	EF 平均绝对误差 5.39 个百分点；左室 Dice 0.908	EchoNet-Dynamic 测试集 1277 段，只评一次
资源与时序	LUT 75.40%、FF 34.0%、BRAM 63.2%、DSP 80.6%；152.15 MHz，WNS +0.486 ns	固件 f150nv，xazu3eg 布线后报告
功耗	PL 动态约 0.9 W；整板 6–7 W	前者 Vivado 估算，后者实测
可复现	同一输入重复 200 次，结果哈希相同	5 段视频 × 2 种运行方式 × 20 次

1.5 主要创新点

（1）**心动周期自适应关键帧调度**：按“EF 只取决于舒张末和收缩末”预测关键帧位置，只把约 18% 的帧送 PL，每帧处理占预算从 121% 降到 26%，EF 误差不升。

（2）**条带调度的自研张量引擎与 6 项实测优化**：512×512 整网从 2076 ms 降到 292.8 ms（约 7.1 倍），每项都有前后对照。

（3）**固定结构引擎与程序包板上逐位自检**：同一比特流运行 9 个心脏程序及眼底、皮肤镜程序，修改为新程序不用改比特流。

1.6 设计流程

设计流程如图 2。模型在 PyTorch 中训练，训练后量化并生成整数参考；

HLS 核在 C 仿真中与整数参考逐位一致后进入 Vivado 集成，按板上实测时钟复核时序；上板后跑全套验收（BoardCheck、测试向量、5000 帧稳定性），任何一项不一致就自动回滚到上一版，定位后重走流程。

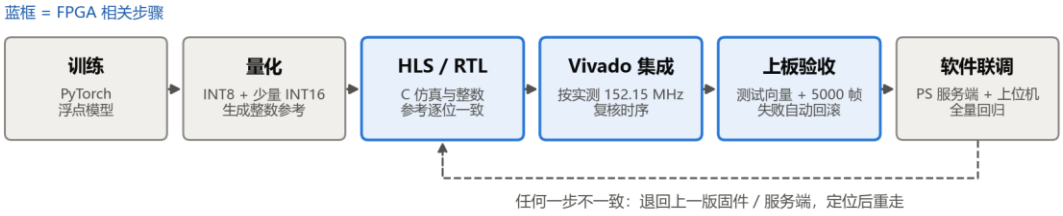


图 2　设计流程（蓝框为 FPGA 相关步骤）

第二部分 系统组成及功能说明

2.1 整体介绍

系统由三部分组成（表 3）。只有 PL 一行算作 FPGA 的贡献；PS 与 PC 上的工作都是软件，下文分开说明。视频帧进入 PS 后，调度器只把约 18% 的关键帧送进 PL 分割，其余帧由 NEON 斑点跟踪传播轮廓；PL 输出的掩膜回到 PS 计算 EF 和全心指标，再交给显示端。

表 3　软硬件分工

平台	承担的工作	关键参数
PL（FPGA，152.15 MHz）	U-Net 分割的全部卷积、逐元素、池化；分割后处理；图像预处理	128 档整网 22.0 ms
PS（4 × A53，Linux）	条带切分与搬运调度、GDMA 读回驱动；关键帧调度与 NEON 跟踪；EF 与全心测量、置信区间、质量灯；TCP 服务	跟踪 0.77 ms / 帧
PC 或板载 DP 显示器	选文件、显示、点击纠错的交互、证据报告	不在实时链路上

图 3 是 PL 内部的数据通路与控制流程：① PS 把条带输入和参数写进张量 BRAM，② 写寄存器启动 IP 并等待完成，③ GDMA 把输出读回 DDR。蓝

色模块由团队自研，灰色为 Xilinx IP 或 PS 硬核。

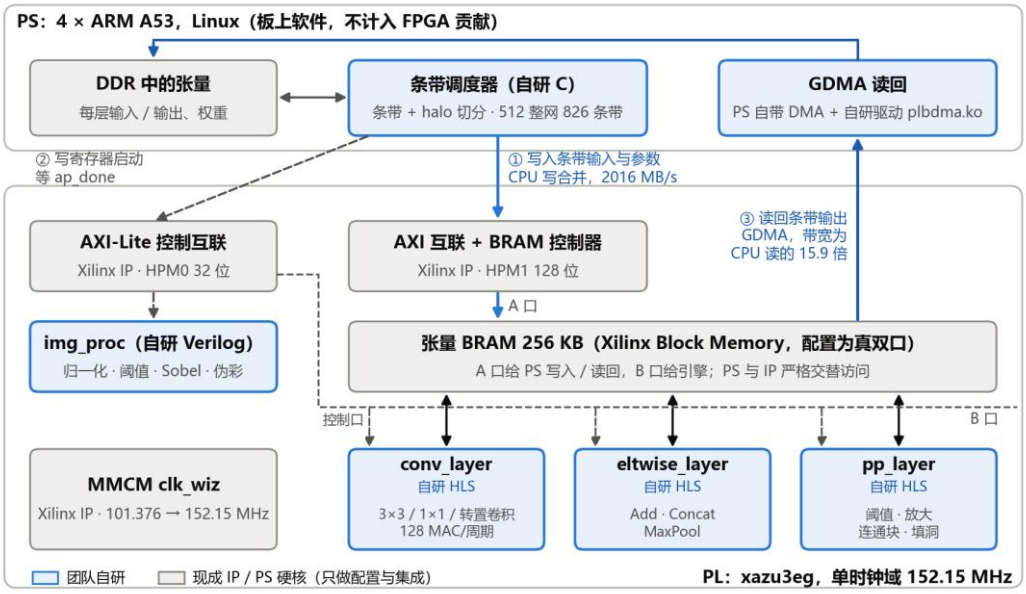


图 3 PL 数据通路与控制流程（实线为数据，虚线为控制）

2.2 硬件系统介绍

2.2.1 硬件整体介绍

硬件平台为 FZ3B 开发板，主芯片 Zynq UltraScale+ xazu3eg（LUT 70,560、FF 141,120、BRAM 216、DSP 360）。PL 中的模块、来源和资源占用见表 4；另有 MMCM、复位和 Zynq PS 为 Xilinx IP 或硬核。U-Net 结构取自开源 lwnet [12]，3.4 万参数，各程序用各自的数据重新训练和量化。

表 4　PL 模块、来源与资源（f150nv 布线后分层报告）

模块	来源	功能	LUT	FF	BRAM	DSP
conv_layer	自研 HLS	3×3 / 1×1 / 转置卷积，峰值 128 MAC/周期	27,028	25,203	39	185
eltwise_layer	自研 HLS	Add、Concat、MaxPool	13,842	10,082	21	76
pp_layer	自研 HLS	阈值、放大、最大连通块、填洞	8,375	9,165	11	28
img_proc 及控制	自研 Verilog + Xilinx 互联	归一化、阈值、Sobel、伪彩	1,219	1,262	1.5	1
张量 BRAM 与互联	Xilinx IP（配置为真双口）	256 KB 张量缓存	2,725	2,295	64	0
合计			**53,203（75.40%）**	**48,045（34.0%）**	**136.5（63.2%）**	**290（80.6%）**

2.2.2 机械设计介绍

本作品使用现成开发板，没有机械设计。

2.2.3 电路各模块介绍（按问题组织）

问题一：片上存不下整层张量。 全片 BRAM 约 0.97 MB，而 512 档一层张量就有 4 MB，开发板出厂配置下 PL 也没有直接访问 DDR 的通路。我们让张量常驻 PS 的 DDR，每个网络节点按条带（带 halo）切分，使每个条带的输入和输出都能放进 256 KB 张量 BRAM：PS 写入条带输入与参数，写寄存器启动 IP，完成后把输出读回 DDR。512 档整网共 826 条带。张量 BRAM 为真双口，A 口给 PS，B 口给引擎；实测两侧同时访问会得到坏数据，所以调度上严格交替。

问题二：PS 读 PL 太慢。 首次跑通时 512 整网要 2076 ms。耗时分解发

现瓶颈在搬运：CPU 每读一次 PL 约 198 ns 且不能流水。我们自写内核模块 plbdma.ko，用 PS 自带的 GDMA 读回整条带，带宽为 CPU 读的 15.9 倍；写入保留 CPU 写合并（实测 2016 MB/s，为端口上限的 83%）。再让上一条带的读回与下一条带的写入并行（图 4），把 42.2 ms 搬运藏进另一条 AXI 通道。

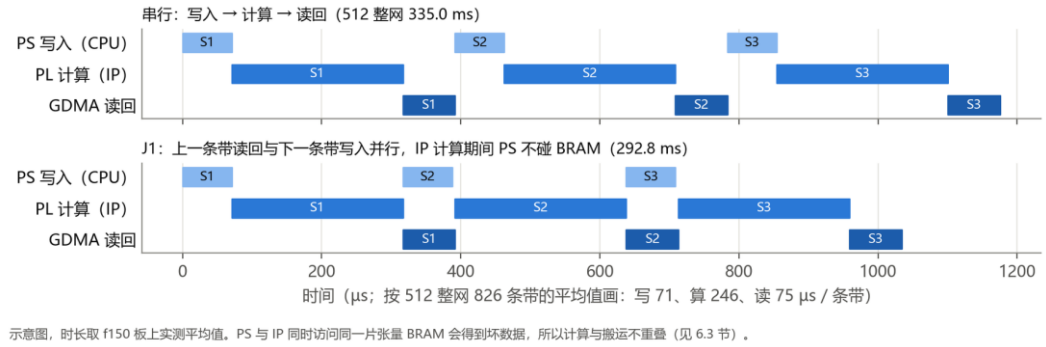


图 4　条带调度时序（按 512 整网每条带的实测平均耗时绘制）

问题三：卷积算得慢、时钟偏低。 3×3 卷积占 PL 计算的 78%，主循环已经 II = 1。我们让卷积每周期并行两个输出列（XU = 2），把张量 BRAM 改为真双口以消除读写方向切换的等待，并合并逐元素算子的访存；最后用 MMCM 把 PL 从 101.376 MHz 提到 152.15 MHz，各 HLS 核按 6.757 ns 重新综合，所有循环的 II 不变，协同仿真全部通过。布线后按实际时钟复核：WNS +0.486 ns、WHS +0.015 ns，最差路径为 0 级逻辑。最后去掉心脏主线不用的 vis_layer（原用于配准代价和叠加显示，这部分改由 PS 完成），得到现用固件 f150nv：LUT 从 84.75% 降到 75.40%，BRAM 从 79.6% 降到 63.2%；同一测试程序前后对照，各档整网耗时变化在 ±2% 以内，输出逐位相同。

各项优化都在同一块板、同一测试程序下做前后对照，输出逐位相同（图 5）。合计 512 整网从 2076 ms 降到 292.8 ms，约 7.1 倍。

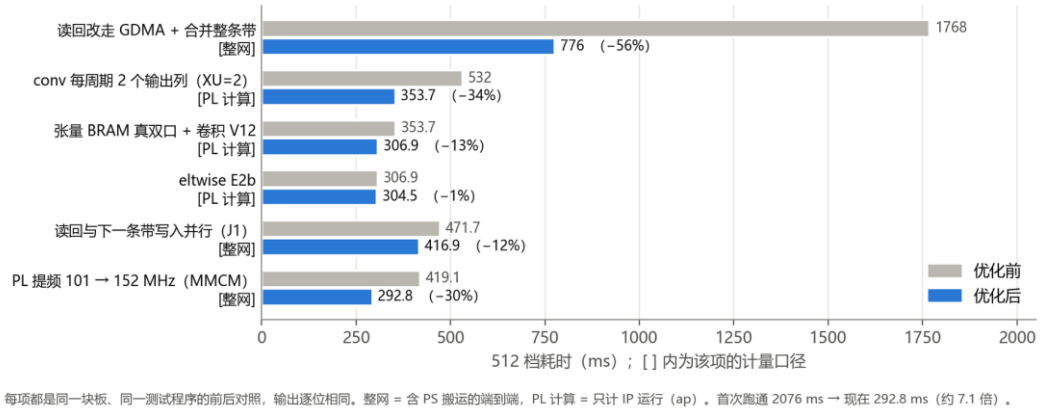


图 5　各项优化的前后实测（512 档；[ ] 内为该项的计量口径）

定点化。 采用训练后量化，权重和激活为 INT8。每个模型最多 2 个对量化最敏感的节点用 INT16，其输入拆成高、低字节分别做 INT8 卷积再合并，所有乘积和部分和都在 2^24 以内，结果为精确整数。EchoNet 左室验证集 Dice：浮点 0.9059、全 INT8 0.9049、混合精度 0.9066。

2.3 软件系统介绍

2.3.1 软件整体介绍

PS 上运行 C 语言服务端，负责条带调度、关键帧调度、跟踪、测量和通信；上位机（Python / Tk）只负责选文件、显示和生成报告，可在 PC 上运行，也可整体运行在板上、接 DP 显示器使用。现场模式下每一帧的处理流程如图 6：输入为灰度帧，输出为每帧掩膜和容积，以及每 0.25 s 一次的滚动 EF。

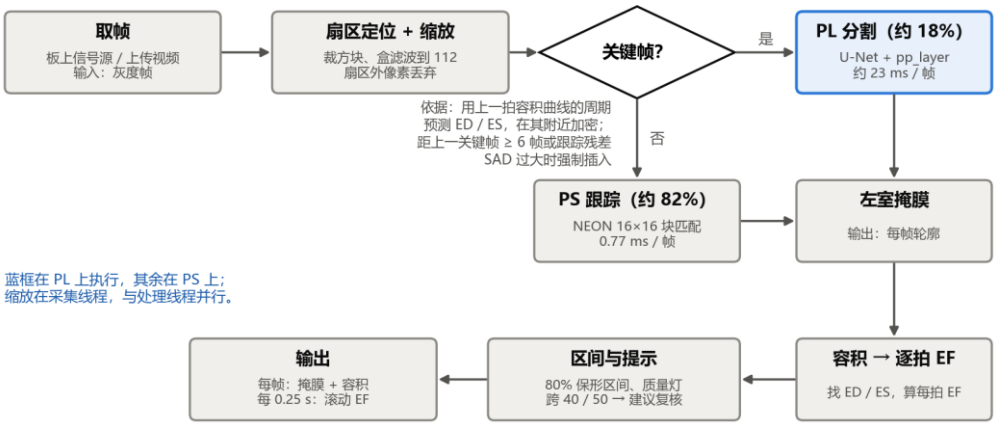


图 6　现场模式逐帧处理流程

2.3.2 软件各模块介绍（按问题组织）

问题四：PL 处理一帧耗时 22.9 ms，跟不上 50 fps。 若每帧都送 PL，处理线程每帧需 24.3 ms（预算的 121%），未处理的帧不断累积。EF 只取决于舒张末（ED）和收缩末（ES）两帧，因此调度器用上一拍的周期预测本拍 ED / ES 的时刻，在其附近加密关键帧；其余帧由 PS 用 NEON 做 16×16 块全搜索，把轮廓传过去（三步搜索在斑点图上只有 94/120 正确，故用全搜索），跟踪残差过大时强制插入关键帧。工作点按“关键帧最少且 Dice 损失低于门限”选取（表 5）。与按固定周期或置信度选关键帧的通用方法 [13]–[15] 不同，这里用的是心动周期先验，不增加硬件。

表 5　关键帧策略（EchoNet 验证集，主机仿真）

策略	关键帧占比	Dice（损失）	EF MAE
每帧推理	100%	0.9108	5.42
推荐档：间隔上限 6 帧 + 残差触发	17.8%	0.9068（−0.44%）	5.35
固定每 8 帧	12.8%	0.9041（−0.73%）	5.46
间隔上限 12 帧	8.6%	0.8982（−1.38%）	5.76

需要跟踪：间隔 8 帧时若直接沿用上一关键帧的掩膜，EF MAE 为 5.57；

加跟踪后为 5.46。板上实测见 3.3 节。

问题五：输出结果如何获得医生信任。 EF 区间用分割式保形预测 [16] 在验证集上校准，给出 80% 区间；区间跨过 40% 或 50%（ESC 2021 分型界值）时显示“分型待定，建议复核”。质量灯不加模型，由分割结果算 9 个规则特征，用逻辑回归给出红、黄、绿灯，CAMUS 验证集上区分差图像的 AUC 为 0.911。医生暂停后左键补漏、右键去多，FPGA 重算该帧（22 ms），再从纠正后的轮廓逐帧重算后续各帧；可撤销，结果写入证据报告。

问题六：新任务怎么上板。 引擎结构固定，输入尺寸、权重、量化移位都作为数据下发，每套 INT8 权重约 34 KB。新程序打包为程序包，服务端运行时加载，先在 PL 上跑包内测试向量，与整数参考逐位一致才注册。右室、右房程序就是这样上线的，比特流没有改动。

第三部分 完成情况及性能参数

3.1 整体介绍

作品实物为一块 FZ3B 开发板，经网线连接 PC，或经 DP 接口连接显示器、USB 接键鼠独立运行（图 7）。

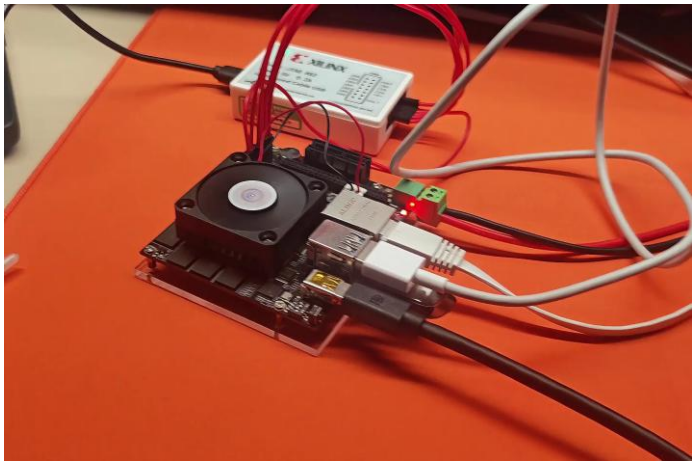


图 7 作品实物（斜 45°）

3.2 工程成果

3.2.1 机械成果

无（使用现成开发板）。

3.2.2 电路成果

FPGA 设计已生成比特流并部署在板上（图 8），开机自动加载。资源与时序见表 4；每次更换固件都跑全套上板验收：BoardCheck 31 项、pp_layer 182 个测试向量、连续 5000 帧稳定性测试，现用固件 f150nv 全部逐位通过。实时性等板上计时在去掉 vis_layer 之前的 f150 上测得，两版的 U-Net 与后处理电路相同。

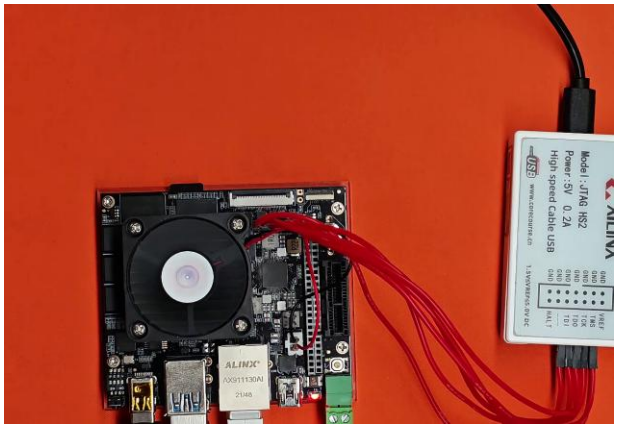


图 8　FZ3B 开发板（俯视，右侧为 JTAG 下载器）

3.2.3 软件成果

上位机为一个主窗口、三种模式。图 9 为现场模式真板运行画面：信号源为板上预录的 HMC-QU 录屏，132 帧中 PL 推理 24 帧（18.2%），EF 41%，80% 区间 32–50% 跨过 40%，系统标“建议复核”，并给出节段室壁运动提示和 RV/LV、RA/LV 面积比。图 10 为快照模式的双平面 Simpson 测量：EDV 160 mL、ESV 97 mL、EF 39%（数据集参考值 40%），板上计算 345 ms。



图 9　现场模式真板运行界面（画面来自 HMC-QU，CC BY-NC-SA 3.0 IGO）

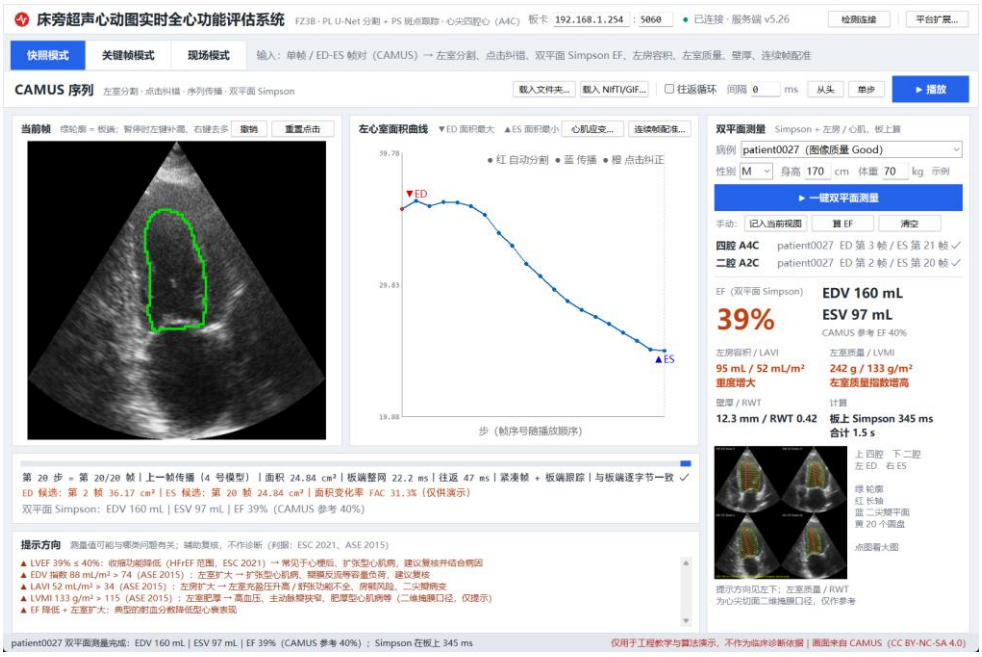


图 10　快照模式双平面测量（画面来自 CAMUS，CC BY-NC-SA 4.0）

3.3 特性成果

实时性。 50 fps 信号源 174 帧，板上时间戳实测（表 6、图 11）：推荐档每帧处理 5.1 ms，延迟呈锯齿、始终在 80 ms 以内；每帧推理时处理线程超出

预算，延迟线性上涨。延迟中的两部分是等待：关键帧要等之后 40 ms 的帧到达才能做时序编码，关键帧后的两三帧要排队等它算完。

表 6　每帧预算（板上时间戳，174 帧，50 fps）

步骤	推荐档	每帧推理
PL 推理（编码 + U-Net + 后处理）	23.0 ms × 17.8% = 4.10 ms	22.9 ms
PS 跟踪	0.77 ms × 82.2% = 0.63 ms	—
收尾（容积等）	0.37 ms	1.42 ms
处理线程合计	5.1 ms（预算的 26%）	24.3 ms（121%）
延迟（采到帧 → 掩膜 + 容积）	P50 29 ms、P99 67 ms，不累积	涨到 841 ms

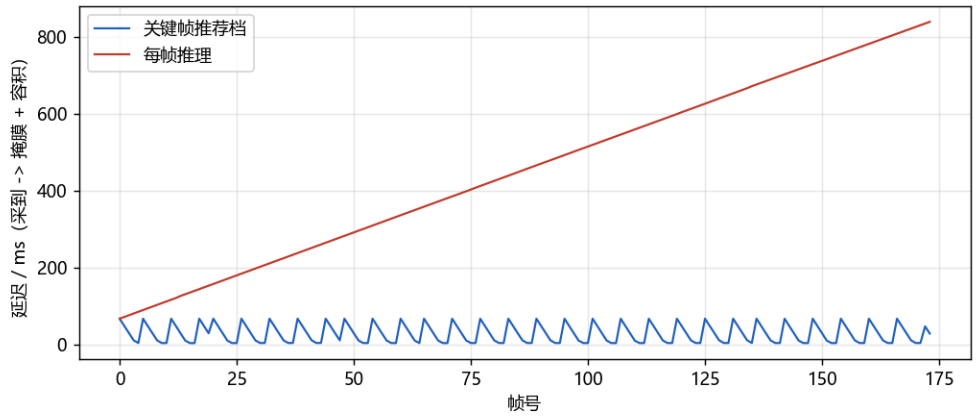


图 11　板上实测逐帧延迟（蓝：推荐档；红：每帧推理）

与同板 CPU 对比。 CPU 基线是同一整数模型的 C 实现，在同一块板的 A53 上运行，输出与 PL 逐位相同（图 12）。128 档 PL 22.0 ms、只占 1 个核，4 核 NEON 34.8 ms 且占满 4 个核；4 线程 CPU 满载干扰下，512 整网中 IP 运行时间仍为 203.3 ms，与空载相同。

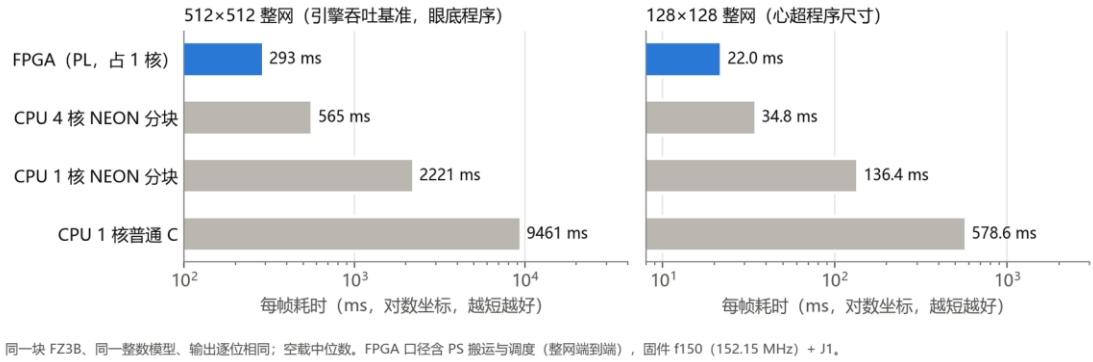


图 12　同板 CPU 与 FPGA 的整网耗时（对数坐标）

与已发表工作对比。 表 7 选取两项最接近的工作：Smistad 等 [17] 是 GPU 上的实时 EF 系统(同一任务)，Rubio 等 [18] 是 FPGA 上的超声分割(同一平台类型)。

表 7　与已发表工作的对比

项目	本作品	Smistad 等 2020 [17]	Rubio 等 2025 [18]
任务	A4C 左室分割 → 逐拍 EF、全心指标	实时 EF 与心尖缩短检测	肺超声 4 类伪影分割
平台	xazu3eg，PL 自研引擎	笔记本：i7-6700 + GTX 980M GPU	Kria KV260 + Vitis AI DPU（厂商 IP）
分割网络	U-Net，3.4 万参数，INT8 / INT16	U-Net，约 200 万参数	U-Net，INT8，参数量未报告
输入尺寸	128 × 128	256 × 256	256 × 128
速度	单帧整网 22.0 ms；系统 50 fps 不丢帧，P99 67 ms	全流程平均 42 fps	单次推理 12.5 ms，> 80 次/s
实时闭环	是，取帧到结果全在板上，实测尾延迟	是，超声机推流到笔记本	否，离线批处理，尚未接入采集
精度	EF MAE 5.39（1277 段）；Dice 0.908	EF 平均绝对差 7.2%，偏差 −3.6 ± 8.1%（100 例）	Dice 0.71–0.97（4 类）
功耗	PL 动态估算约 0.9 W；整板实测 6–7 W	未报告	未实测

三项工作的数据集不同，精度只能看量级。与 GPU 方案相比，本作品的网

络参数约为其 1/58，在一块小规模 FPGA 板上达到 50 fps 不丢帧，高于其 42 fps；与 KV260 方案相比，对方单次推理更快（输入像素是我们的 2 倍），但使用厂商 DPU、离线批处理，未给出端到端链路，本作品则是自研引擎、板上闭环并实测了尾延迟。另有 Kang 等 [19] 在数据中心级 XCU250 器件上用 hls4ml 部署了 6 万参数以下的 U-Net，CAMUS 上 Dice 0.7352，未公开延迟和资源数值。

精度。 四个测试集都是公开数据；方法、门限和校准只用训练集和验证集确定，写好预注册文件后每个测试集只评一次，数字来自与板上逐位相同的整数模型（表 8）。

表 8　测试集结果（预注册后各评一次）

测试集（样本）	结果	局限
EchoNet-Dynamic [20]（1277 段）	左室 Dice 0.908；EF MAE 5.39、r 0.80；80% 区间覆盖 0.80；EF ≤ 40 的 AUC 0.951	EF ≤ 40 灵敏度 0.54，靠复核兜底：160 段中 98.1% 判出或标复核
HMC-QU [21]（65 段）	整段室壁运动异常 AUC 0.90，灵敏度 0.757、特异度 0.857	单用 EF 的 AUC 也是 0.90
CardiacUDA [22]（47 段）	右室 Dice 0.776，右房 0.877	右室比验证集低 0.05
CAMUS [23]（50 例）	左房容积 MAE 11.0 mL，左室质量 MAE 24.8 g	左房被扇区截断时不报容积

可复现与功耗。 5 段验证集视频 × 2 种运行方式各在板上重复 20 次，每组只有 1 个结果哈希。Vivado 按布线后网表估算（默认翻转率）片上合计 4.04 W，其中 PS 2.82 W、PL 动态约 0.9 W、静态 0.33 W；整板实测 6–7 W。板上没有电流传感器，无法单独测出 PL 功耗，所以不与 GPU 比能效。

第四部分 总结

4.1 可扩展之处

一是接真实超声机：UVC 采集路径已写好，采集卡到货后实测“超声机屏幕 → 显示器”的端到端延迟。二是扩展切面和指标：短轴、胸骨旁长轴切面，以及心包积液、下腔静脉等。三是扩展到其他影像：引擎只需换权重，眼底、皮肤镜程序已在同一比特流上运行。

4.2 心得体会

第一，先测量再优化。项目初期整网要 2 秒多，直觉是 PL 算力不够，耗时分解却显示时间几乎都花在 PS 和 PL 之间的搬运上。之后每一项优化都先做分解、再改、再在板上对照，有几次直觉上可行的方案（例如搬运与计算重叠、INT8 打包）在测量后被否决，大幅度优化系统性能。

第二，面向使用者设计。医生需要的不只是一个 EF 数字，还要知道这个数可不可信、哪一帧可能有问题。因此系统给出区间和复核提示，允许点击纠错，并把计算过程写进证据报告，而不下诊断。

第三，分工与协作。团队按图像处理与硬件、模型训练与部署、板级系统与交互三条线分工，围绕同一条板上数据链路推进，接口约定和验收脚本共享，跨模块问题共同排查。

第五部分 参考文献

[1] McDonagh T A, Metra M, Adamo M, et al. 2021 ESC Guidelines for the diagnosis and treatment of acute and chronic heart failure[J]. European Heart Journal, 2021, 42(36): 3599–3726.

[2] Hao G, Wang X, Chen Z, et al. Prevalence of heart failure and left ventricular dysfunction

in China: the China Hypertension Survey, 2012–2015[J]. European Journal of Heart Failure, 2019, 21(11): 1329–1337.

[3] Gordon E P, Schnittger I, Fitzgerald P J, et al. Reproducibility of left ventricular volumes by two-dimensional echocardiography[J]. Journal of the American College of Cardiology, 1983, 2(3): 506–513. DOI: 10.1016/S0735-1097(83)80278-2.

[4] Garcia-Elcano L, Bossa M N, Garcia-Sineriz I, et al. Accurate estimation of interobserver variability in echocardiography segmentation measured from 35 experts and impact on derived clinical metrics[J]. European Heart Journal – Cardiovascular Imaging, 2025, 26(Supplement_1): jeae333.044（会议摘要）. DOI: 10.1093/ehjci/jeae333.044.

[5] Akil S, Castaings J, Thind P, et al. Impact of experience on visual and Simpson's biplane echocardiographic assessment of left ventricular ejection fraction[J]. Clinical Physiology and Functional Imaging, 2025, 45(1): e12918. DOI: 10.1111/cpf.12918.

[6] Altes A, Pécriaux V, Hanvi P, et al. Association of preoperative cardiac magnetic resonance and echocardiography with postoperative left ventricular dysfunction in primary mitral regurgitation[J]. Journal of the American Society of Echocardiography, 2026, 39(1): 28–40. DOI: 10.1016/j.echo.2025.09.015.

[7] Hjorth-Hansen A K, Magelssen M I, Andersen G N, et al. Real-time automatic quantification of left ventricular function by hand-held ultrasound devices in patients with suspected heart failure: a feasibility study of a diagnostic test with data from general practitioners, nurses and cardiologists[J]. BMJ Open, 2022, 12(10): e063793. DOI: 10.1136/bmjopen-2022-063793.

[8] Sakamoto A, Kaneko T, Sato E, et al. Artificial intelligence in echocardiography: current applications and future perspectives[J]. Journal of Echocardiography, 2025, 23(4): 231–240. DOI: 10.1007/s12574-025-00703-0.

[9] Nazari M, Emami H, Rabiei R, et al. Development and clinical usability assessment of a web-based AI platform for automated echocardiography analysis[J]. Computer Methods and Programs in Biomedicine, 2026, 285: 109490. DOI: 10.1016/j.cmpb.2026.109490.

[10] Nguyen A H, Zhao J, et al. Validation of real-time artificial intelligence-guided cardiac point-of-care ultrasound to guide management by non-cardiologist providers: the AISAP-INOVA pilot study[C]// American Society of Echocardiography 2026 Scientific Sessions. 2026（会议报告）.

[11] Doğan M, Ertenli C U, Güngör M O, et al. A portable ultrasound system integrating a CMUT sensor array with an FPGA-based delay-and-sum beamformer[C]// AMA Science Proceedings.〔出处未核实：卷期、页码、年份待补〕

[12] Galdran A, Anjos A, Dolz J, et al. State-of-the-art retinal vessel segmentation with

minimalistic models[J]. Scientific Reports, 2022, 12: 6174.

[13] Zhu Y, Samajdar A, Mattina M, et al. Euphrates: algorithm-SoC co-design for low-power mobile continuous vision[C]// ISCA, 2018.

[14] Buckler M, Bedoukian P, Jayasuriya S, et al. EVA²: exploiting temporal redundancy in live computer vision[C]// ISCA, 2018.

[15] Xu Y S, Fu T J, Yang H K, et al. Dynamic video segmentation network[C]// CVPR, 2018.

[16] Lei J, G'Sell M, Rinaldo A, et al. Distribution-free predictive inference for regression[J]. Journal of the American Statistical Association, 2018, 113(523): 1094–1111.

[17] Smistad E, Østvik A, Salte I M, et al. Real-time automatic ejection fraction and foreshortening detection using deep learning[J]. IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control, 2020. DOI: 10.1109/TUFFC.2020.2981037.

[18] Rubio A, Muñoz M, Cosarinsky G, et al. Hardware acceleration of convolutional neural network for lung ultrasound segmentation[C]// Forum Acusticum 2025. Málaga, 2025: 2179–2183. DOI: 10.61782/fa.2025.0426.

[19] Kang J, Al-Qurri A, Almekkawy M. Fast and resource-efficient ultrasound segmentation using FPGAs[C]// 2025 IEEE International Ultrasonics Symposium (IUS). Utrecht, 2025. DOI: 10.1109/IUS62464.2025.11201783.

[20] Ouyang D, He B, Ghorbani A, et al. Video-based AI for beat-to-beat assessment of cardiac function[J]. Nature, 2020, 580: 252–256.

[21] Degerli A, Zabihi M, Kiranyaz S, et al. Early detection of myocardial infarction in low-quality echocardiography[J]. IEEE Access, 2021, 9: 34442–34453.

[22] Yang J, Ding X, Zheng Z, et al. GraphEcho: graph-driven unsupervised domain adaptation for echocardiogram video segmentation[C]// ICCV, 2023.

[23] Leclerc S, Smistad E, Pedrosa J, et al. Deep learning for segmentation using an open large-scale dataset in 2D echocardiography[J]. IEEE Transactions on Medical Imaging, 2019, 38(9): 2198–2210.